

VAE_261004: 从统计学基础到 ELBO

Junhan Learning Notes

2026-10-04

目录

0. 一页思维链：先把整个 VAE 串起来	2
0.1 目标：学习一个能生成数据的模型	3
0.2 生成方向：先有潜变量，再有观测	3
0.3 边缘化：只关心 x ，把所有可能的 z 加起来	3
0.4 观察到 x 后，真正想反推的是 posterior	4
0.5 瓶颈：真正 posterior 通常难算	4
0.6 于是造一个 encoder，直接近似 posterior	4
0.7 ELBO 有两个等价视角	4
视角 A：它离真正目标还差多少	4
视角 B：实际训练时怎么计算	5
0.8 对应到真实代码，就是这一条操作链	5
1. 学 RL / VAE 前最值得补的概率论是什么？	5
2. 分布、随机变量和一次采样	6
3. 联合、条件、边缘：一张表看懂	6
3.1 联合概率	7
3.2 条件概率	7
3.3 边缘概率到底是什么意思？	7
4. Bayes：同一个联合概率，从两个方向分解	8
4.1 prior 和 posterior 的最直观区别	8
5. 期望：把随机结果变成一个平均目标	8
5.1 理论期望和样本平均	9
6. 方差与高斯分布	9
7. KL：比较两个概率分配规则	10
7.1 关于 forward / reverse KL 的 mode-covering 与 mode-seeking	10
8. VAE 中所有 p/q 符号放回同一张图	11
8.1 生成模型	11
8.2 精确 posterior	11
8.3 encoder 近似 posterior	11

9. $q(x, z)$ 、 $q(x)$ 、 $q(z)$ 又是什么?	11
10. ELBO 原式的分子、分母到底在做什么?	12
11. ELBO 为什么是下界? 视角 A: 和真正 posterior 的差距	12
12. ELBO 为什么可训练? 视角 B: 重建 + prior KL	13
13. “ $p(z)$ 不是随机采样的吗?” ——分布和采样必须彻底分开	13
14. 为什么不能让 $q_\phi(z x)$ 完全等于 $p(z)$?	14
15. Reparameterization trick: 怎样让采样过程可反向传播?	14
16. 代码里的 loss 怎样对应数学?	15
17. 从概率论直接桥接到 RL	15
17.1 策略也是分布	15
17.2 价值函数是条件期望	15
17.3 Monte Carlo 是用样本估计期望	16
17.4 KL 在 RL 中也经常用来限制策略变化	16
18. 最容易混淆的十句话	16
19. 以后看任何概率模型公式, 可以用同一套检查法	16
20. 文件对应关系	17

0. 一页思维链: 先把整个 VAE 串起来

先别从 ELBO 公式开始背。VAE 最清楚的读法是: 目标 -> 生成方向 -> 精确反推 -> 计算瓶颈 -> 近似推断 -> 可训练目标 -> 代码操作。

先把整条链压成一屏:

Goal:	$\max_{\theta} \log p_{\theta}(x)$
Generate:	$z \sim p(z), \quad x \sim p_{\theta}(x z)$ $p_{\theta}(x, z) = p(z)p_{\theta}(x z)$
Marginal:	$p_{\theta}(x) = \int p(z)p_{\theta}(x z) dz$
Exact posterior:	$p_{\theta}(z x) = \frac{p(z)p_{\theta}(x z)}{p_{\theta}(x)}$
Bottleneck:	$p_{\theta}(x)$ 的积分通常难算
Approximate:	$q_{\phi}(z x) \approx p_{\theta}(z x)$
Train:	ELBO = $\mathbb{E}_q[\log p_{\theta}(x z)] - \text{KL}(q \ p(z))$
Code:	$x \rightarrow (\mu, \log \sigma^2) \rightarrow z \rightarrow \hat{x}$
Generate after training:	$z \sim \mathcal{N}(0, I) \rightarrow \text{decoder}.$

0.1 目标：学习一个能生成数据的模型

我们想让模型给真实数据 x 高概率：

$$\max_{\theta} \log p_{\theta}(x).$$

0.2 生成方向：先有潜变量，再有观测

VAE 假设：

$$\boxed{z \sim p(z)} \implies \boxed{x \sim p_{\theta}(x | z)}$$

因此生成模型的联合分布是：

$$\boxed{p_{\theta}(x, z) = p(z)p_{\theta}(x | z)}.$$

其中：

- $p(z)$: **prior**, 先验。还没看见当前 x 时, 对 z 的规定；标准 VAE 常设 $p(z) = \mathcal{N}(0, I)$ 。
- $p_{\theta}(x | z)$: **decoder**。给定 z 后, 模型认为哪些 x 可能出现。

0.3 边缘化：只关心 x , 把所有可能的 z 加起来

$$\boxed{p_{\theta}(x) = \int p(z)p_{\theta}(x | z) dz}$$

“边缘化”只表示：不再区分另一个变量，把它所有可能性求和/积分掉。

0.4 观察到 x 后，真正想反推的是 posterior

Bayes 公式给出：

$$p_{\theta}(z | x) = \frac{p(z)p_{\theta}(x | z)}{p_{\theta}(x)}$$

这里：

$$p(z) = \text{prior}, \quad p_{\theta}(z | x) = \text{posterior}.$$

最容易记错的一点：先验不是 $p(z | x)$ 。一旦条件里出现当前观测 x ，它已经是看见数据之后的判断。

0.5 瓶颈：真正 posterior 通常难算

因为 Bayes 的分母：

$$p_{\theta}(x) = \int p(z)p_{\theta}(x | z) dz$$

在高维神经网络里通常无法精确积分。

0.6 于是造一个 encoder，直接近似 posterior

$$q_{\phi}(z | x) \approx p_{\theta}(z | x)$$

标准 VAE 中，encoder 常输出：

$$\mu_{\phi}(x), \quad \sigma_{\phi}(x)$$

并定义：

$$q_{\phi}(z | x) = \mathcal{N}(\mu_{\phi}(x), \text{diag}(\sigma_{\phi}^2(x))).$$

注意： $q_{\phi}(z | x)$ 是一个分布； $z \sim q_{\phi}(z | x)$ 才是一次随机采样。

0.7 ELBO 有两个等价视角

视角 A：它离真正目标还差多少

$$\log p_{\theta}(x) = \text{ELBO}(x) + D_{\text{KL}}(q_{\phi}(z | x) \| p_{\theta}(z | x))$$

因为 $D_{\text{KL}} \geq 0$ ：

$$\text{ELBO}(x) \leq \log p_{\theta}(x).$$

这告诉我们：

encoder 的近似 posterior 越接近真正 posterior，下界越紧。

视角 B：实际训练时怎么计算

同一个 ELBO 也可写成：

$$\text{ELBO}(x) = \mathbb{E}_{q_\phi(z|x)}[\log p_\theta(x|z)] - D_{\text{KL}}(q_\phi(z|x) \| p(z))$$

第一项要求：

z 要足以解释当前 x 。

第二项要求：

$q_\phi(z|x)$ 不要偏离统一的 prior 太离谱。

所以 VAE 不是“只重建”，也不是“强迫所有图片都编码成同一个高斯”。它是在二者之间优化平衡。

0.8 对应到真实代码，就是这一条操作链

$$x \xrightarrow{\text{encoder}} (\mu, \log \sigma^2) \xrightarrow{\text{reparameterize}} z \xrightarrow{\text{decoder}} \hat{x}$$

训练时最小化：

$$\mathcal{L}_{\text{train}} = -\text{ELBO} = \underbrace{-\mathbb{E}_q[\log p_\theta(x|z)]}_{\text{reconstruction / NLL}} + \underbrace{D_{\text{KL}}(q_\phi(z|x) \| p(z))}_{\text{latent regularization}}$$

生成新样本时则不需要 encoder：

$$z \sim \mathcal{N}(0, I) \longrightarrow x \sim p_\theta(x|z)$$

这就是整套 VAE 的骨架。后面所有公式都应该能挂回这条链上。

1. 学 RL / VAE 前最值得补的概率论是什么？

不需要先把完整统计学教材学完。对 VAE 和 RL，最重要的是先把下面几件事吃透：

1. 分布和一次采样不是一回事；
2. 联合、条件、边缘概率如何互相转换；
3. Bayes 如何把“生成方向”变成“观察后的反推”；
4. 期望如何把随机结果变成一个可优化的平均目标；

5. 采样平均如何近似理论期望;
6. KL 如何比较两个分布;
7. 方差告诉我们估计有多不稳定。

这些东西在 VAE 中出现为 $p, q, \mathbb{E}, \text{KL}$; 在 RL 中则会变成 policy、transition、return、value、Monte Carlo、policy KL 等。

2. 分布、随机变量和一次采样

设随机变量 Z 有分布:

$$p(z).$$

这是一个**概率规则**。例如:

$$p(z) = \mathcal{N}(0, 1).$$

它不是某个具体随机数。

只有写:

$$z \sim p(z)$$

才表示“从这个分布里抽一次”。这次可能得到 $z = 0.37$, 下次可能得到 $z = -1.21$ 。

同理:

$$q_\phi(z | x)$$

是 encoder 对当前 x 给出的**分布**;

$$z \sim q_\phi(z | x)$$

才是从它里面采一个 latent sample。

3. 联合、条件、边缘：一张表看懂

设隐藏类型 $Z \in \{A, B\}$, 图片类型 $X \in \{\text{猫}, \text{狗}\}$ 。假设联合概率如下:

$p(x, z)$	$z = A$	$z = B$	边缘 $p(x)$
$x = \text{猫}$	0.45	0.05	0.50
$x = \text{狗}$	0.05	0.45	0.50
边缘 $p(z)$	0.50	0.50	1.00

3.1 联合概率

“来自 A 并且 是猫”：

$$p(A, \text{猫}) = 0.45.$$

3.2 条件概率

“已知来自 A，是猫的概率”：

$$p(\text{猫} | A) = \frac{p(\text{猫}, A)}{p(A)} = \frac{0.45}{0.50} = 0.9.$$

“已知是猫，来自 A 的概率”：

$$p(A | \text{猫}) = \frac{p(A, \text{猫})}{p(\text{猫})} = \frac{0.45}{0.50} = 0.9.$$

这里数值碰巧相同，不代表一般情况下 $p(x | z) = p(z | x)$ 。

3.3 边缘概率到底是什么意思？

如果有联合分布 $p(x, z)$ ，但现在不关心 z 是什么，就把所有 z 加起来：

$$p(x) = \sum_z p(x, z).$$

反过来：

$$p(z) = \sum_x p(x, z).$$

连续变量时：

$$p(x) = \int p(x, z) dz.$$

“边缘”这个名字来自二维概率表：把内部格子沿一个方向加起来，结果常写在表的边缘（margin）。数学上它没有更神秘的含义。

边缘化 = 把暂时不关心的随机变量求和/积分掉。

4. Bayes: 同一个联合概率, 从两个方向分解

联合分布可以写成:

$$p(x, z) = p(z)p(x | z)$$

也可以写成:

$$p(x, z) = p(x)p(z | x).$$

令两者相等:

$$p(z)p(x | z) = p(x)p(z | x).$$

得到:

$$p(z | x) = \frac{p(x | z)p(z)}{p(x)}.$$

这就是 Bayes 公式。

4.1 prior 和 posterior 的最直观区别

- $p(z)$: 还没看到这次观测 x , 先验上 z 会是什么?
- $p(z | x)$: 已经看到 x , 再重新判断 z 会是什么?

因此:

$$\text{prior: } p(z) \xrightarrow{\text{observe } x} \text{posterior: } p(z | x)$$

5. 期望: 把随机结果变成一个平均目标

如果奖励 R 有若干可能值:

$$\mathbb{E}[R] = \sum_r p(r)r$$

更一般地:

$$\mathbb{E}_{Z \sim p}[f(Z)] = \sum_z p(z)f(z)$$

连续情形:

$$\mathbb{E}_{Z \sim p}[f(Z)] = \int p(z) f(z) dz$$

这里下标 $Z \sim p$ 只是在说：用哪个分布作为加权规则。

5.1 理论期望和样本平均

理论期望可能难算，因此我们从分布里采样：

$$z_1, \dots, z_N \sim p(z)$$

然后估计：

$$\mathbb{E}_{p(z)}[f(z)] \approx \frac{1}{N} \sum_{i=1}^N f(z_i)$$

这就是 Monte Carlo 思想。

VAE 训练时通常对每个 x 只采一个或少量 z ；RL 中 rollout 的 return 估计本质上也是类似的采样估计。

6. 方差与高斯分布

均值告诉我们“平均在哪里”，方差告诉我们“有多散”：

$$\text{Var}(Z) = \mathbb{E}[(Z - \mathbb{E}[Z])^2]$$

高斯分布写作：

$$Z \sim \mathcal{N}(\mu, \sigma^2).$$

标准 VAE 的 encoder 常输出每一维 latent 的：

$$\mu_i(x), \quad \log \sigma_i^2(x).$$

用它们定义一个对角高斯近似 posterior。

7. KL：比较两个概率分配规则

离散情形：

$$D_{\text{KL}}(Q\|P) = \sum_x Q(x) \log \frac{Q(x)}{P(x)}$$

连续情形：

$$D_{\text{KL}}(q\|p) = \int q(z) \log \frac{q(z)}{p(z)} dz$$

它可以读成：

按照 Q 实际会去到的位置，对“ Q 和 P 在这里差多少”做平均。

所以 KL 不对称：

$$D_{\text{KL}}(Q\|P) \neq D_{\text{KL}}(P\|Q)$$

通常成立。

7.1 关于 forward / reverse KL 的 mode-covering 与 mode-seeking

一种常见教学约定是把目标分布记为 P ，近似模型记为 Q ：

$$D_{\text{KL}}(P\|Q)$$

会严重惩罚“ P 有概率但 Q 几乎没有概率”的区域，因此常被描述为 **mode-covering**。

而：

$$D_{\text{KL}}(Q\|P)$$

主要在 Q 自己有质量的地方计分，因此当 Q 的表达能力受限时，常出现 **mode-seeking** 的行为。

但这只是对特定逼近问题的常用直觉，不应机械记成“所有 forward KL 一定覆盖、所有 reverse KL 一定找峰”。最终行为还取决于参数化、支持集、优化问题等。

更重要的是：

P 、 Q 只是字母。它们不天然表示“真实”和“模型”。

VAE 里常写：

- p_θ ：生成模型；
- q_ϕ ：近似推断模型。

8. VAE 中所有 p/q 符号放回同一张图

8.1 生成模型

$$p_{\theta}(x, z) = p(z)p_{\theta}(x | z)$$

生成方向：

$$z \rightarrow x.$$

8.2 精确 posterior

$$p_{\theta}(z | x) = \frac{p(z)p_{\theta}(x | z)}{p_{\theta}(x)}$$

这是生成模型自身根据 Bayes 定义出来的反推分布。

8.3 encoder 近似 posterior

$$q_{\phi}(z | x) \approx p_{\theta}(z | x)$$

这里 q 并不是“decoder 反推出来”的；它是我们额外训练的一个 inference network，用来跳过难算的 Bayes 分母。

9. $q(x, z)$ 、 $q(x)$ 、 $q(z)$ 又是什么？

如果定义 inference-side joint:

$$q(x, z) = p_{\text{data}}(x)q_{\phi}(z | x)$$

它对应操作：

$$x \sim p_{\text{data}}(x) \quad \longrightarrow \quad z \sim q_{\phi}(z | x).$$

把 z 边缘化：

$$q(x) = \int q(x, z)dz = p_{\text{data}}(x).$$

把 x 边缘化：

$$q(z) = \int p_{\text{data}}(x)q_{\phi}(z | x) dx$$

可以把它想成：

- $q(z | x)$: 一张图片对应的一小团 latent 云;
- $q(z)$: 整个数据集所有小云混起来后的总体 latent 分布。

10. ELBO 原式的分子、分母到底在做什么?

ELBO 的一个定义是:

$$\text{ELBO}(x) = \mathbb{E}_{q_\phi(z|x)} \left[\log \frac{p(z)p_\theta(x|z)}{q_\phi(z|x)} \right]$$

分子:

$$p(z)p_\theta(x|z) = p_\theta(x, z)$$

确实是生成模型的联合密度。

但它不是在说“decoder 这一次已经采样出了一个 x ”。当前训练样本 x 已经固定。我们是在问:

对 encoder 提议的某个 z , 生成模型给当前 pair (x, z) 多高的概率密度?

分母:

$$q_\phi(z|x)$$

仍然只是固定当前 x 后, encoder 对 z 的分布。

它不是“对应输入 x 的分布”, 也没有把 z 再反推成一个新的 x 分布。

11. ELBO 为什么是下界? 视角 A: 和真正 posterior 的差距

Bayes:

$$p_\theta(z|x) = \frac{p(z)p_\theta(x|z)}{p_\theta(x)}.$$

等价地:

$$p(z)p_\theta(x|z) = p_\theta(x)p_\theta(z|x).$$

代回 ELBO:

$$\text{ELBO}(x) = \mathbb{E}_q \left[\log \frac{p_\theta(x)p_\theta(z|x)}{q_\phi(z|x)} \right].$$

因为当前 x 固定, $\log p_\theta(x)$ 与 z 无关:

$$\text{ELBO}(x) = \log p_{\theta}(x) - D_{\text{KL}}(q_{\phi}(z | x) \| p_{\theta}(z | x)).$$

因此：

$$\log p_{\theta}(x) = \text{ELBO}(x) + D_{\text{KL}}(q_{\phi}(z | x) \| p_{\theta}(z | x))$$

这条式子回答的是：

这个可计算下界离真正 log-likelihood 还有多远？

12. ELBO 为什么可训练？视角 B：重建 + prior KL

从原定义直接拆 log：

$$\begin{aligned} \text{ELBO}(x) &= \mathbb{E}_q[\log p_{\theta}(x | z) + \log p(z) - \log q_{\phi}(z | x)] \\ &= \mathbb{E}_q[\log p_{\theta}(x | z)] - D_{\text{KL}}(q_{\phi}(z | x) \| p(z)). \end{aligned}$$

这里出现了两个不同的 KL：

KL	比较什么	作用
$D_{\text{KL}}(q_{\phi}(z x) \ p_{\theta}(z x))$	近似 posterior vs 真正 posterior	描述 ELBO 与真实目标的 gap
$D_{\text{KL}}(q_{\phi}(z x) \ p(z))$	当前样本的近似 posterior vs prior	出现在实际可计算训练式中

二者千万不要混成一个 KL。

13. “ $p(z)$ 不是随机采样的吗？”——分布和采样必须彻底分开

标准 VAE 常固定：

$$p(z) = \mathcal{N}(0, I).$$

这是一个分布，不是一组本次随机数。

训练某个 x 时，encoder 得到：

$$q_{\phi}(z | x) = \mathcal{N}(\mu_{\phi}(x), \text{diag}(\sigma_{\phi}^2(x))).$$

然后才采样：

$$z \sim q_{\phi}(z | x).$$

生成新数据时才直接：

$$z \sim p(z) = \mathcal{N}(0, I).$$

所以训练中的 prior KL 更准确地理解为：

$p(z)$ 通常固定，优化主要推动 $q_\phi(z | x)$ 不要离 prior 太远。

不是“先从 $p(z)$ 抽了一个数，再让这个数逼近 encoder 的分布”。

14. 为什么不能让 $q_\phi(z | x)$ 完全等于 $p(z)$ ？

如果对所有 x 都有：

$$q_\phi(z | x) = p(z),$$

那 encoder 就完全不依赖输入。

猫、狗、数字 1、数字 8 全部得到同一个 latent 分布， z 不再携带关于 x 的信息。

因此 VAE 有两个方向的拉力：

$$\underbrace{\mathbb{E}_q[\log p_\theta(x | z)]}_{\text{保留足够信息来解释 } x} - \underbrace{D_{\text{KL}}(q_\phi(z | x) \| p(z))}_{\text{让 latent 空间保持统一、可采样}}$$

如果第二项压得过强，可能出现 posterior collapse：decoder 基本忽略 z 。

15. Reparameterization trick：怎样让采样过程可反向传播？

如果直接写：

$$z \sim \mathcal{N}(\mu_\phi(x), \sigma_\phi^2(x)),$$

随机采样节点不好直接对 ϕ 传普通路径导数。

于是把随机性移到一个与 ϕ 无关的变量：

$$\epsilon \sim \mathcal{N}(0, I)$$

再写：

$$z = \mu_\phi(x) + \sigma_\phi(x) \odot \epsilon$$

现在随机的是 ϵ ，而 z 对 μ, σ 是普通可微函数，梯度可以穿过 encoder。

代码里常用：

$$\sigma = \exp\left(\frac{1}{2} \log \sigma^2\right).$$

16. 代码里的 loss 怎样对应数学?

如果 decoder 把 MNIST 像素建模成 Bernoulli, 训练常写:

$$\mathcal{L}_{\text{recon}} = \text{BCEWithLogits}(x, \text{logits}).$$

它对应负的 reconstruction log-likelihood:

$$-\log p_{\theta}(x \mid z).$$

对标准正态 prior 和对角高斯 posterior:

$$D_{\text{KL}}(q_{\phi}(z \mid x) \parallel p(z)) = -\frac{1}{2} \sum_j (1 + \log \sigma_j^2 - \mu_j^2 - \sigma_j^2)$$

因此代码中:

$$\text{loss} = \text{recon_nll} + \text{kl} = -\text{ELBO}$$

我们最小化 loss, 就等价于最大化 ELBO。

17. 从概率论直接桥接到 RL

VAE 和 RL 虽然任务不同, 但基础语言高度重合。

17.1 策略也是分布

$$\pi_{\theta}(a \mid s)$$

表示给定状态 s 时, 对动作 a 的条件分布。

一次真正行动才是:

$$a \sim \pi_{\theta}(a \mid s).$$

这和 “ $q(z \mid x)$ 是分布, $z \sim q(z \mid x)$ 才是采样” 完全同一种区分。

17.2 价值函数是条件期望

$$V^{\pi}(s) = \mathbb{E}_{\pi}[G_t \mid S_t = s]$$

它就是: 固定当前状态, 在策略和环境导致的所有可能未来上, 对 return 做概率加权平均。

17.3 Monte Carlo 是用样本估计期望

VAE:

$$\mathbb{E}_{q(z|x)}[f(z)] \approx f(z), \quad z \sim q(z|x)$$

(一样本估计)。

RL:

$$V^\pi(s) = \mathbb{E}[G_t | s] \approx \frac{1}{N} \sum_{i=1}^N G_t^{(i)}.$$

17.4 KL 在 RL 中也经常用来限制策略变化

例如把新旧策略的差异限制为:

$$D_{\text{KL}}(\pi_{\text{old}}(\cdot | s) \| \pi_{\text{new}}(\cdot | s))$$

所以现在学清楚 “KL 的方向、按谁加权、分布 vs 样本”，以后看 PPO/TRPO 等会轻松很多。

18. 最容易混淆的十句话

1. $p(z)$ 是 **prior**; $p(z|x)$ 才是 **posterior**。
2. 分布不是样本; $p(z)$ 和 $z \sim p(z)$ 是两件事。
3. 边缘化不是 “设另一个变量为 0”，而是对它的所有可能性求和/积分。
4. $p(x, z) = p(z)p(x|z)$ 永远成立; $p(x, z) = p(x)p(z)$ 只有独立时才成立。
5. **decoder** 给的是 $p_\theta(x|z)$ ，不是直接给 **posterior**。
6. 真正 **posterior** $p_\theta(z|x)$ 是由 **prior** + **decoder** + **Bayes** 一起定义的。
7. **encoder** 的 $q_\phi(z|x)$ 是对真正 **posterior** 的近似。
8. ELBO 中 $p(x, z)/q(z|x)$ 的分母仍然是 z 的分布，不是某个新的 x 分布。
9. ELBO 里有两个不同语义的 KL，不能混淆。
10. 训练 VAE 通常最小化 -ELBO; 生成时只需要 **prior** + **decoder**。

19. 以后看任何概率模型公式，可以用同一套检查法

看到一个新模型时，先不要钻进 loss。依次问：

1. 目标变量是什么？最终到底想建模/优化哪个量？
2. 生成或数据流方向是什么？哪些变量先出现，哪些条件在谁身上？
3. 联合分布怎么分解？
4. 要得到的条件/边缘量是什么？
5. 哪一步精确但不可算？
6. 引入了什么近似对象？为什么非它不可？
7. 训练目标怎样从真正目标推出来？
8. 每一项对应实际代码中的哪个张量/采样/梯度路径？
9. 训练和推理/生成时，哪些模块还存在，哪些模块消失？

10. 把所有内容压成一屏链路，是否还能保持符号含义不变？

如果这十问都能回答，通常就不是“记住公式”，而是真的理解了算法。

20. 文件对应关系

本目录还包含：

- VAE_ 公式完整推导.md：把 ELBO、Jensen、Gaussian KL、reparameterization 等完整推一遍；
- vae_mnist.py：一个可运行的 PyTorch MNIST VAE，代码注释逐项对应上述公式；
- VAE_261004.pdf：本笔记的排版版 PDF。

另有：

- ../../思维链路/VAE_261004.md：总结这次对话如何从零散疑问压成“目标 -> 生成 -> 后验 -> 瓶颈 -> 近似 -> 目标 -> 实现”的可复用讲解链路。